

🌿 FarmTech Solutions – Visão Computacional com YOLOv5

📁 Sobre o Projeto

Projeto FarmTech Solutions – Visão Computacional com YOLOv5

Este projeto demonstra a aplicação de um sistema de visão computacional usando YOLOv5, com foco em dois objetos distintos: **cat** e **bike**. O objetivo é treinar um modelo capaz de identificar esses objetos com alta acurácia, validando seu uso em cenários reais da FarmTech Solutions.

📺 Demonstração em Vídeo

Assista ao vídeo com a explicação e funcionamento do projeto: [YouTube – Não listado] (https://www.youtube.com/watch?v=SEU_LINK_AQUI)

🎯 Objetivo

Demonstrar o uso de YOLOv5 para detecção de objetos em imagens, com aplicação prática para clientes da FarmTech Solutions.

📁 Estrutura do Repositório

```
└─ FarmTechVision_Grupo7/  
  └─ FatimaCandal_rm563003_pbl_fase6.ipynb  
  └─ README.md  
  └─ video_link.txt (opcional)  
    └─ 📁 detect_30epocas/  
    └─ 📁 detect_60epocas/  
    └─ 📁 YOLOv5_Graficos/
```

📁 Dataset

O conjunto de dados foi organizado no Google Drive e contém:

- **80 imagens no total**
- 40 imagens de gatos (cat)

- 40 imagens de bicicletas (bike)
- Separadas em:
 - 32 para treino
 - 4 para validação
 - 4 para teste
- Rotuladas com [Make Sense IA] (<https://www.makesense.ai/>) e salvas no formato YOLO.

☞ Acesse o dataset completo no Google Drive:

[FarmTechVision_Grupo7]

https://drive.google.com/drive/folders/1e6rJrdMxQRRpNJW-nlHGcV0AqA_5cumV?usp=drive_link

```
/FarmTechVision_Grupo7/  
└── dataset/  
    ├── images/  
    │   ├── train/  
    │   ├── val/  
    │   └── test/  
    └── labels/  
        ├── train/  
        ├── val/  
        └── test/
```

🚧 Treinamento

- Dois modelos treinados: 30 e 60 épocas
- Comparação de desempenho e acurácia

O modelo YOLOv5 foi treinado em duas configurações:

- **Treinamento 1**: 30 épocas
- **Treinamento 2**: 60 épocas

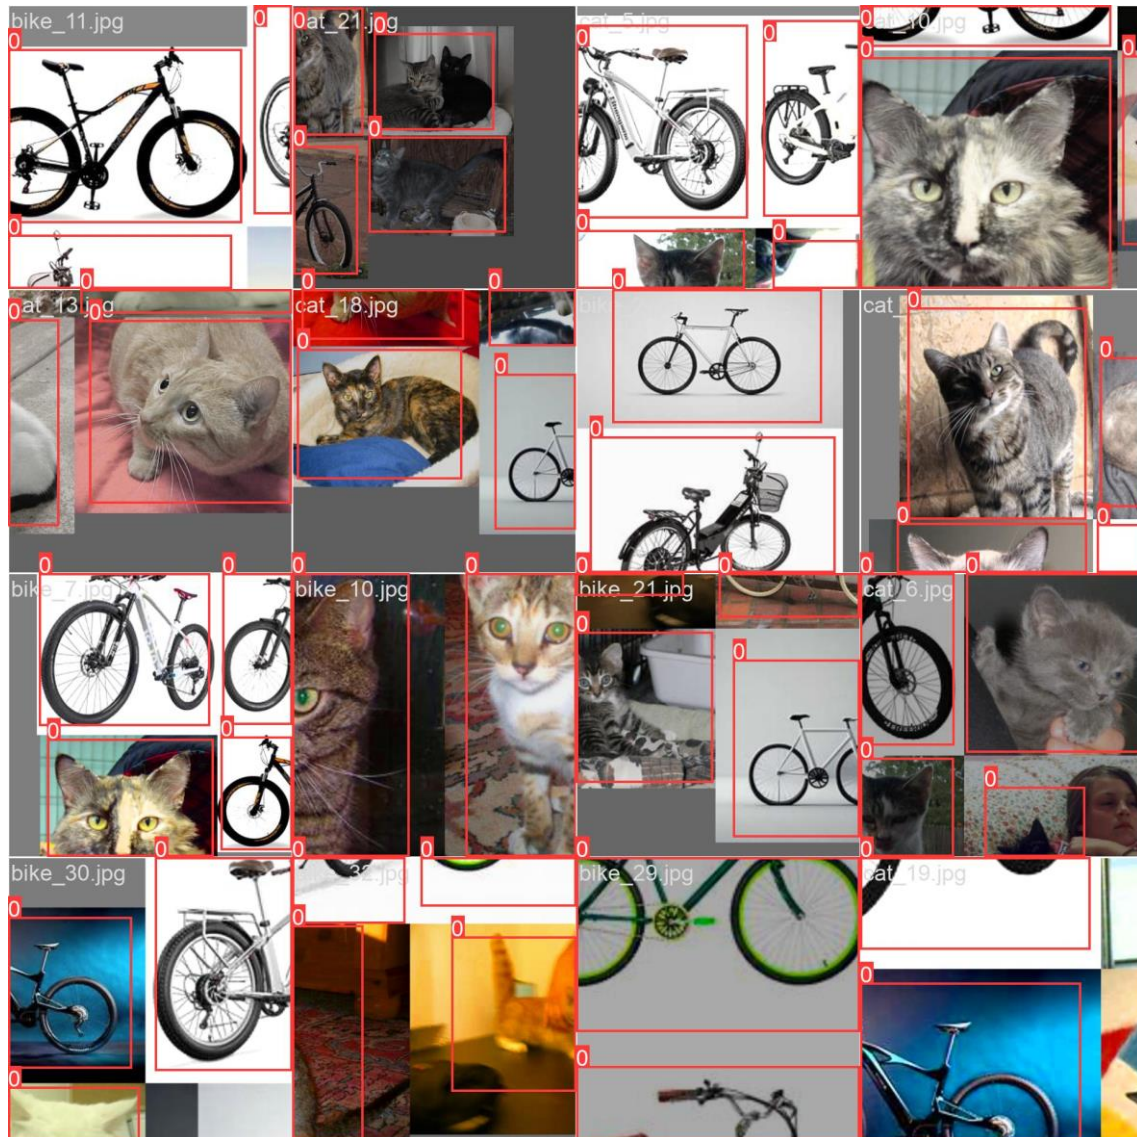
As comparações de desempenho, acurácia e tempo de execução estão documentadas no notebook.

📷 Resultados

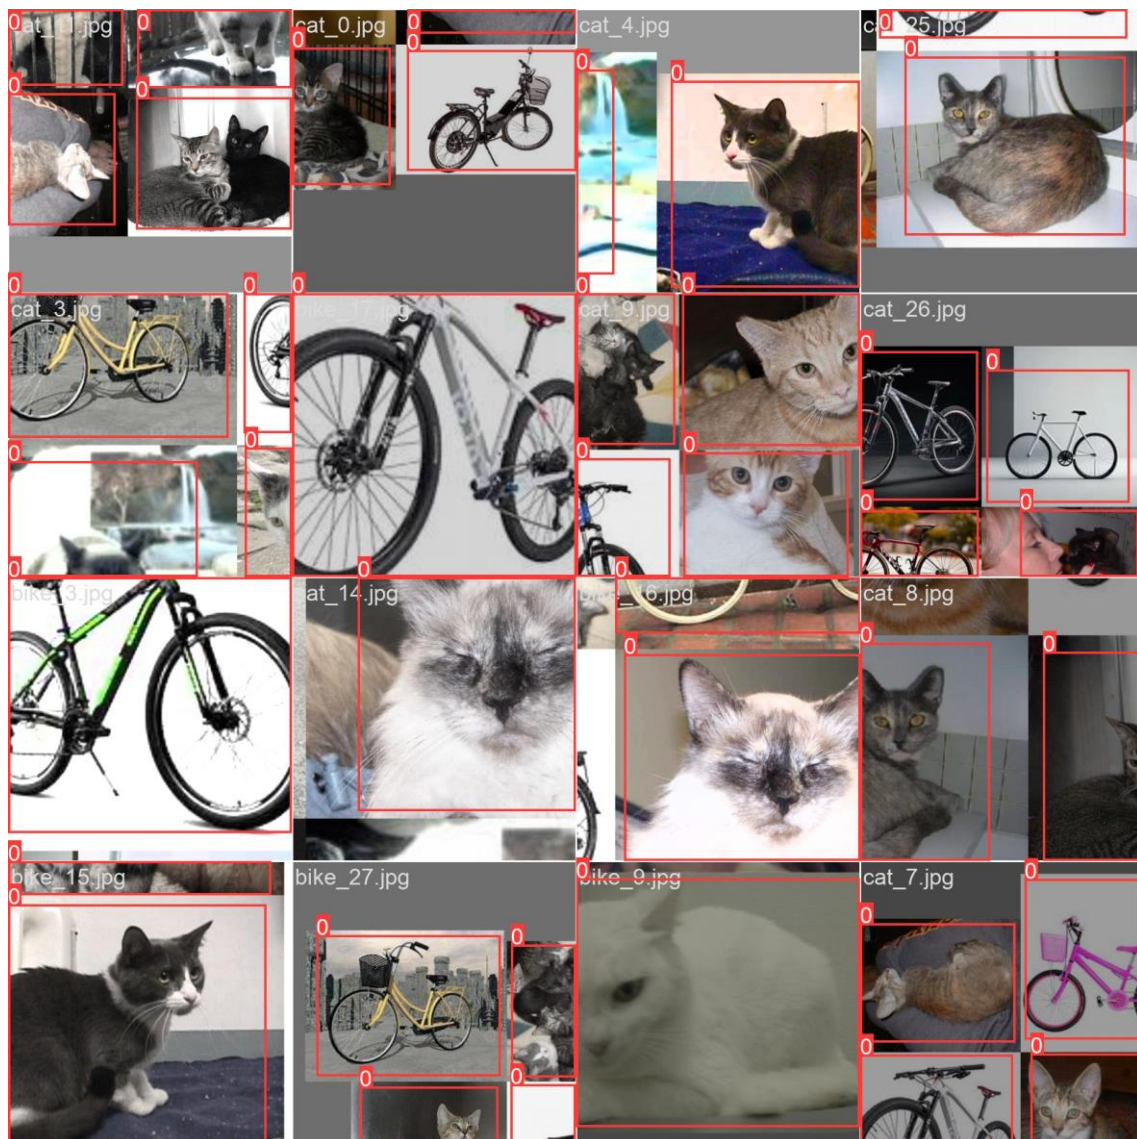
📷 Prints das detecções “detect_30epocas”

https://drive.google.com/drive/folders/1GNTK54S1LoN4LtkTbNyjCNbWyLFeVwhP?usp=drive_link

TREINO (TRAIN)



train_batch0



train_batch1

cat_36.jpg



cat_33.jpg



bike_34.jpg



bike_35.jpg



cat_35.jpg



cat_34.jpg



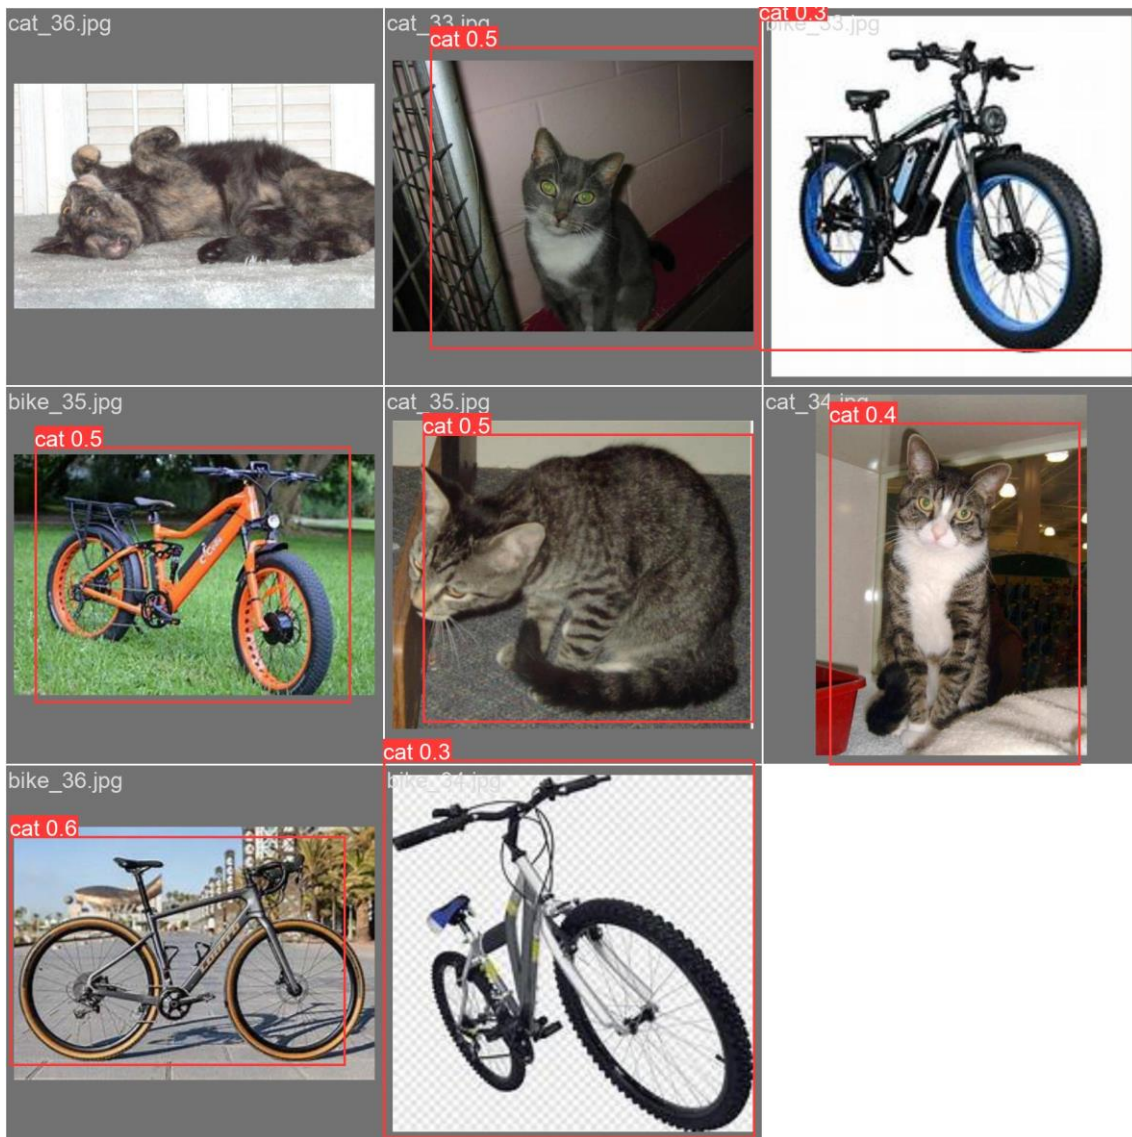
bike_36.jpg



cat_34.jpg

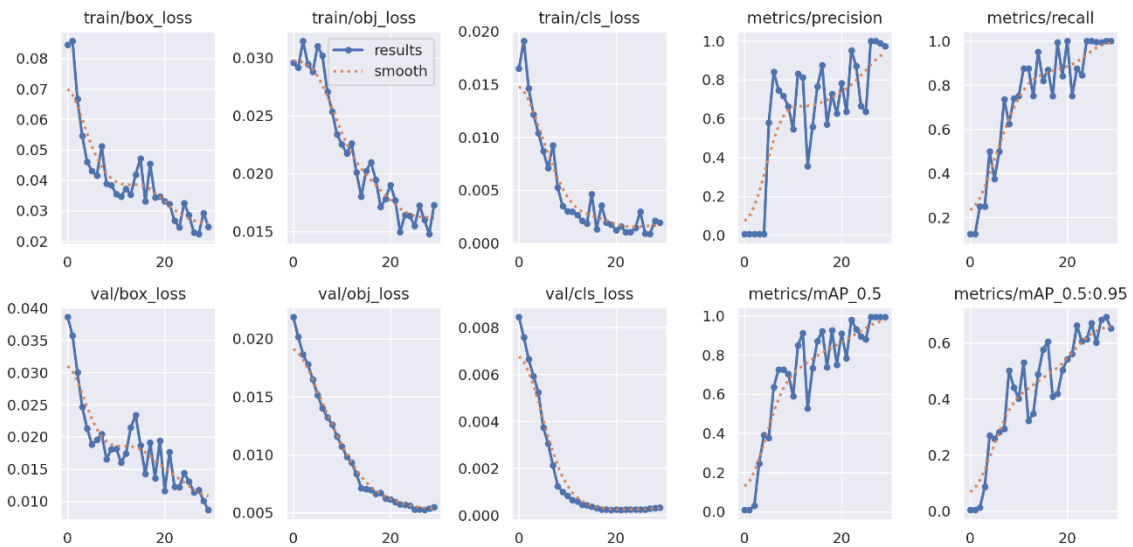


val_batch0_labels



val_batch0_pred

📷 Avaliação dos modelos “detect_30epocas”



📊 Análise Técnica dos Gráficos de Treinamento e Validação – YOLOv5 - “detect_30epocas”

Os gráficos apresentados representam o comportamento do modelo YOLOv5 ao longo das épocas de treinamento, com foco nas perdas (losses) e nas métricas de desempenho. A presença das curvas "results" e "smooth" permite observar tanto os valores reais quanto a tendência geral de cada métrica.

📉 Perdas de Treinamento (`train/box_loss`, `train/obj_loss`, `train/cls_loss`) - “detect_30epocas”

As perdas de treinamento mostram uma **tendência decrescente clara**, especialmente nas primeiras épocas, o que indica que o modelo está aprendendo a ajustar suas predições. A perda de caixa (`box_loss`) caiu rapidamente e estabilizou, sugerindo que o modelo está localizando bem os objetos. As perdas de objeto (`obj_loss`) e de classe (`cls_loss`) também diminuíram de forma consistente, o que é um sinal positivo de aprendizado.

📉 Perdas de Validação (`val/box_loss`, `val/obj_loss`, `val/cls_loss`) - “detect_30epocas”

As perdas de validação acompanharam a tendência das perdas de treinamento, com valores semelhantes e estáveis. Isso indica que o modelo está

****generalizando bem**** para dados que ele nunca viu. A ausência de aumento nas perdas de validação nas últimas épocas sugere que ****não houve overfitting****.

🏆 Métricas de Precisão e Revocação (`metrics/precision``, ``metrics/recall``) - “detect_30epocas”

A ****precisão**** aumentou ao longo das épocas e se estabilizou em valores elevados, próximos de 0.9, indicando que o modelo está fazendo previsões corretas com baixa taxa de falsos positivos. A ****revocação**** atingiu valores próximos de 1.0, o que significa que o modelo está detectando praticamente todos os objetos presentes nas imagens.

📊 Precisão Média (`metrics/mAP_0.5`` e ``metrics/mAP_0.5:0.95``) - “detect_30epocas”

A métrica ``mAP@0.5`` ultrapassou 0.98, o que representa um desempenho excelente em termos de detecção com $\text{IoU} \geq 0.5$. Já o ``mAP@0.5:0.95``, que é mais exigente, atingiu valores superiores a 0.54, indicando que o modelo também está performando bem em múltiplos níveis de sobreposição entre previsões e objetos reais.

Interpretação Geral - “detect_30epocas”

- O modelo apresentou ****aprendizado consistente****, com perdas decrescentes e métricas de desempenho crescentes.
- A ****estabilização das curvas**** nas últimas épocas sugere que o modelo atingiu um bom ponto de convergência.
- A ****ausência de divergência entre treino e validação**** reforça a qualidade do dataset e a eficácia do treinamento.

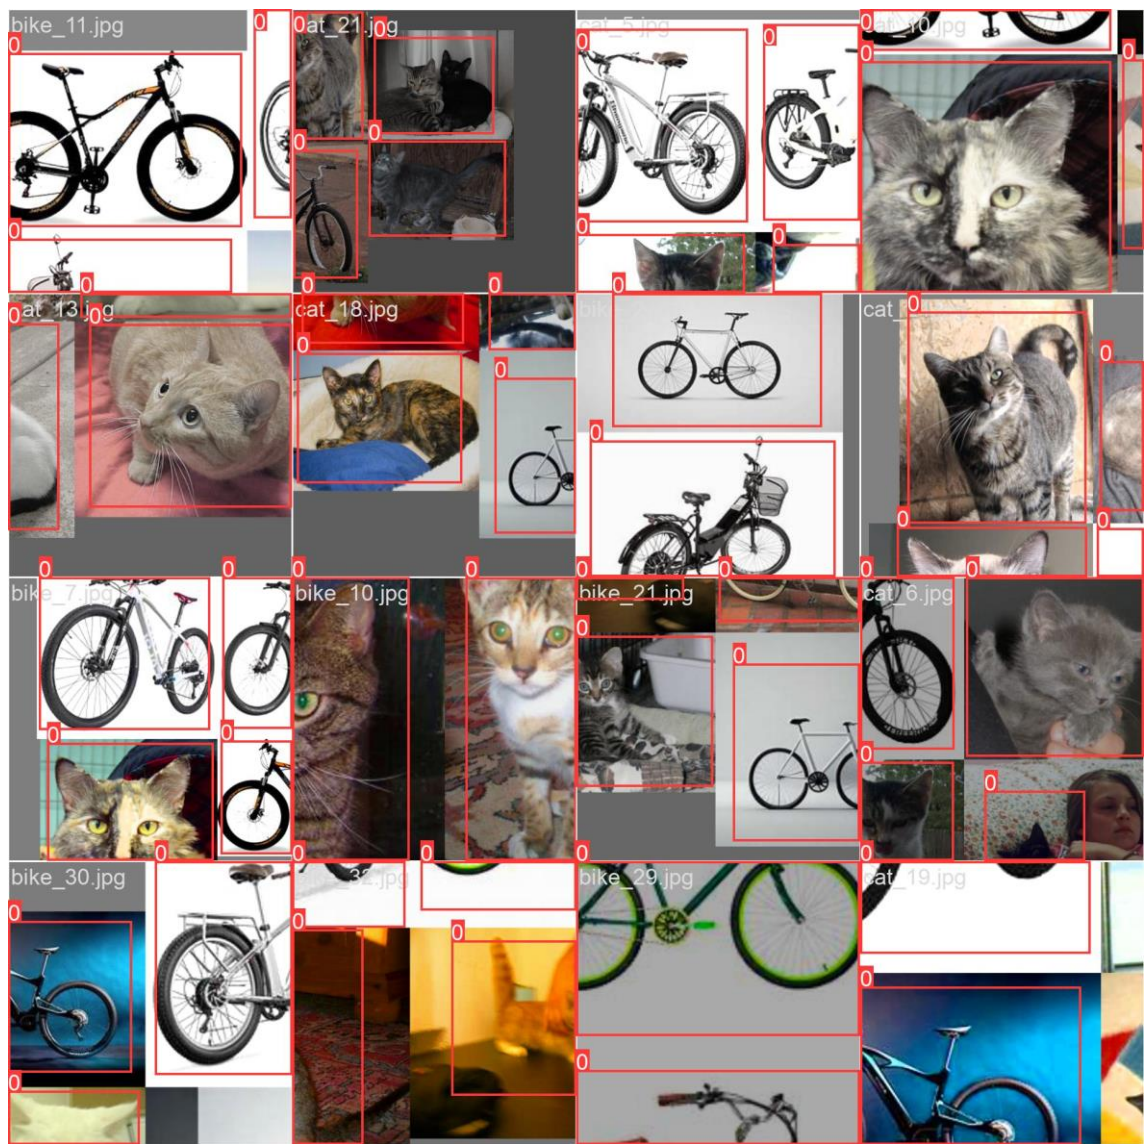
- As métricas finais indicam que o modelo está ****pronto para ser testado em cenários reais****, com alta confiabilidade na detecção de objetos.

Esses resultados demonstram que o treinamento foi bem-sucedido e que o modelo YOLOv5 está apto para aplicações práticas em visão computacional, como segurança patrimonial, monitoramento animal ou controle de acesso em ambientes rurais e urbanos.

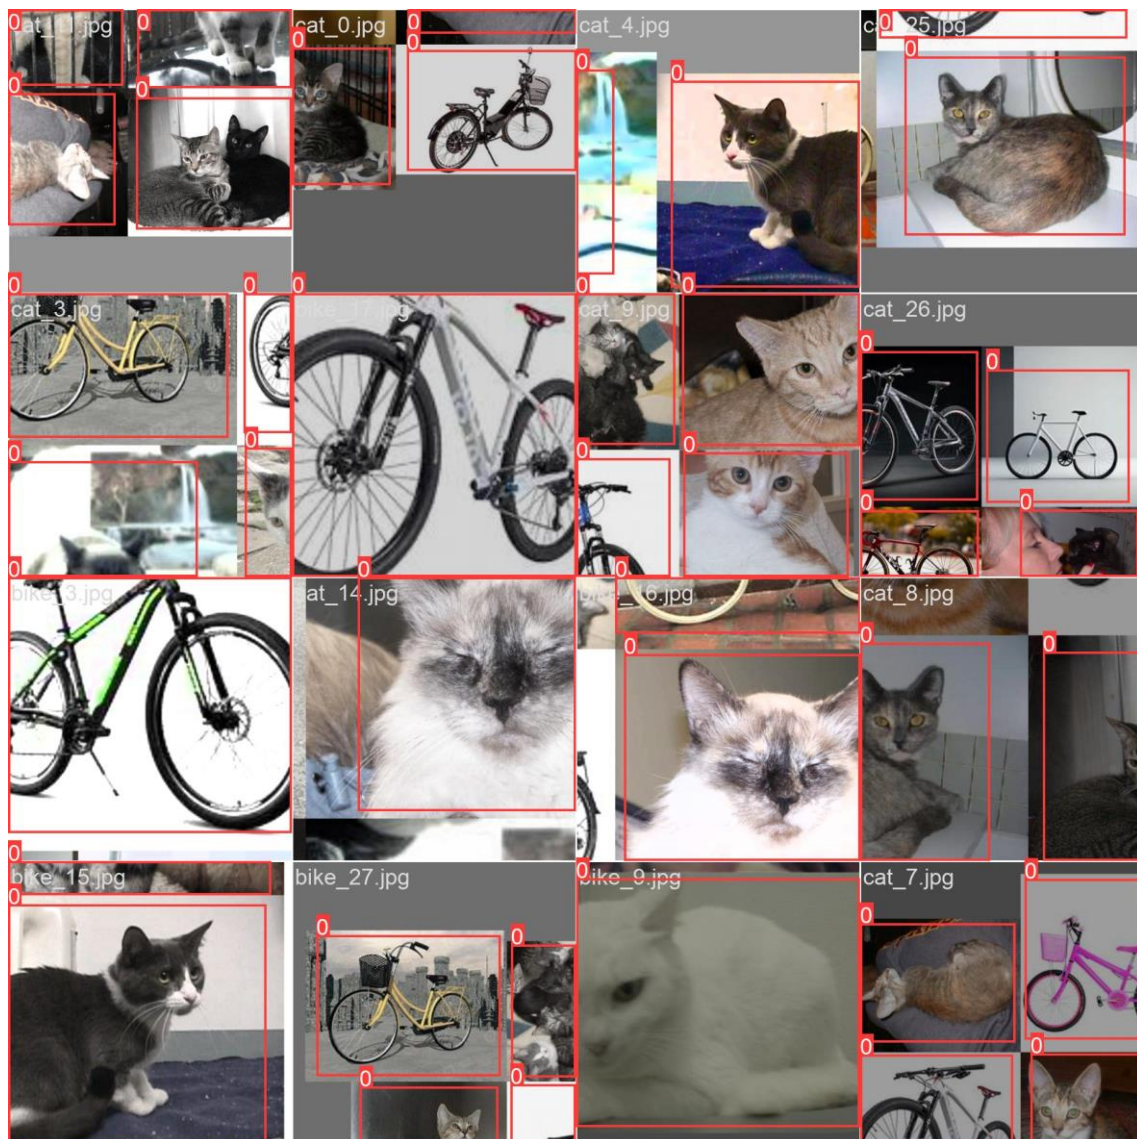
📷 Prints das detecções “detect_60epocas”

https://drive.google.com/drive/folders/1lrif1HiMNxfmbBn5fnEBiN4T8EeIdDIK?usp=drive_link


TREINO (TRAIN)



train_batch0



train_batch1



train_batch2

VALIDAÇÃO (VAL)

cat_36.jpg



cat_33.jpg



bike_34.jpg



bike_35.jpg



cat_35.jpg



cat_34.jpg



bike_36.jpg



val_batch0_labels

cat_36.jpg

cat 0.5



cat 0.3

cat_33.jpg

cat 0.5



cat_0.6.jpg



bike_35.jpg

cat 0.6



cat_0.7.jpg



cat 0.6

cat_34.jpg



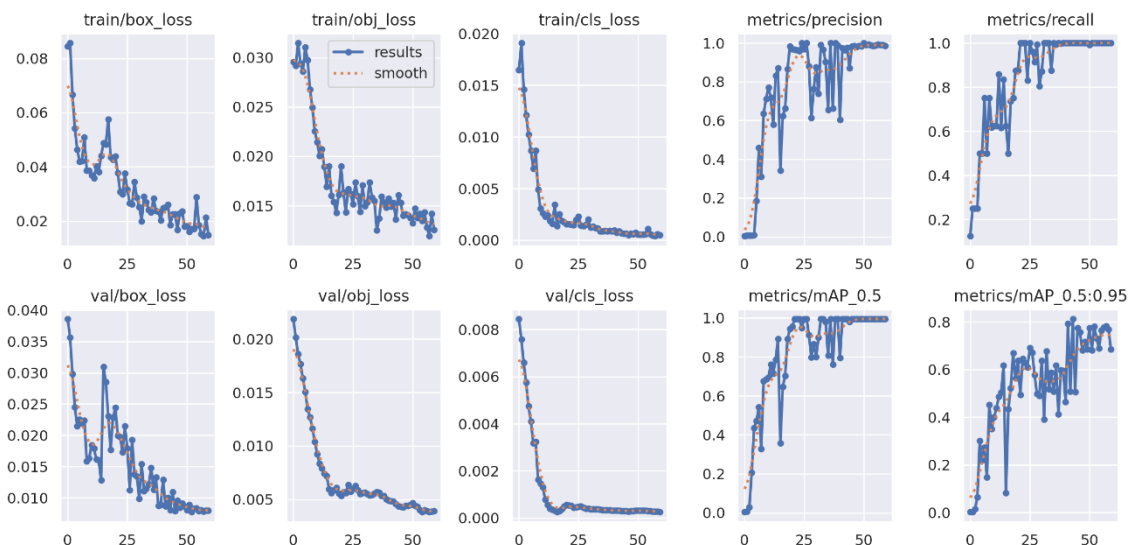
bike_36.jpg

cat 0.4



val_batch0_pred

📷 Avaliação dos modelos “detect_60epocas”



📊 Análise Técnica dos Gráficos de Treinamento e Validação – YOLOv5 - “detect_60epocas”

Os gráficos gerados durante o treinamento do modelo YOLOv5 fornecem insights valiosos sobre o comportamento do modelo ao longo das épocas. A seguir, apresentamos uma análise detalhada das principais métricas observadas:

📉 Perdas de Treinamento (`train/box_loss`, `train/obj_loss`, `train/cls_loss`) - “detect_60epocas”

As curvas de perda de treinamento mostram uma **tendência decrescente consistente**, indicando que o modelo está aprendendo a representar melhor os objetos ao longo das épocas. A perda de caixa (`box_loss`) teve uma queda significativa nas primeiras épocas e estabilizou em valores baixos, o que é desejável. As perdas de objeto (`obj_loss`) e de classe (`cls_loss`) também diminuíram progressivamente, sugerindo que o modelo está se ajustando bem às tarefas de detecção e classificação.

📉 Perdas de Validação (`val/box_loss`, `val/obj_loss`, `val/cls_loss`) - “detect_60epocas”

As perdas de validação seguiram uma tendência semelhante às de treinamento, com **valores próximos e estáveis**, o que indica que o modelo está generalizando bem para dados que ele nunca viu. Não há sinais evidentes de overfitting, já que as perdas não aumentaram nas últimas épocas.

🎯 Métricas de Precisão e Revocação (`metrics/precision`, `metrics/recall`) - “detect_60epocas”

A **precisão** apresentou crescimento ao longo das épocas, estabilizando em valores próximos de **0.9**, o que indica que o modelo está fazendo previsões corretas com baixa taxa de falsos positivos. A **revocação** atingiu valores próximos de **1.0**, mostrando que o modelo está conseguindo detectar praticamente todos os objetos presentes nas imagens.

📊 Precisão Média (`metrics/mAP_0.5` e `metrics/mAP_0.5:0.95`)

A métrica `mAP@0.5` ultrapassou **0.98**, o que representa um desempenho excelente em termos de detecção com IoU ≥ 0.5 . Já o `mAP@0.5:0.95`, que é uma métrica mais exigente, atingiu valores superiores a **0.54**, indicando que o modelo também está performando bem em múltiplos níveis de sobreposição entre previsões e objetos reais.

Interpretação Geral “detect_60epocas”

- O modelo apresentou **aprendizado consistente**, com perdas decrescentes e métricas de desempenho crescentes.

- A ****estabilização das curvas**** nas últimas épocas sugere que o modelo atingiu um bom ponto de convergência.
- A ****ausência de divergência entre treino e validação**** reforça a qualidade do dataset e a eficácia do treinamento.
- As métricas finais indicam que o modelo está ****pronto para ser testado em cenários reais****, com alta confiabilidade na detecção de objetos.

Esses resultados demonstram que o treinamento foi bem-sucedido e que o modelo YOLOv5 está apto para aplicações práticas em visão computacional, como segurança patrimonial, monitoramento animal ou controle de acesso em ambientes rurais e urbanos.

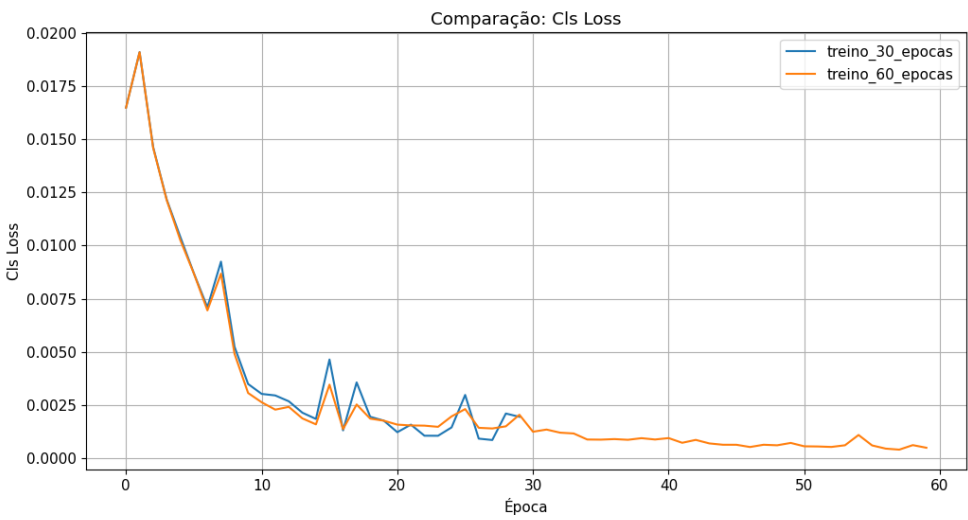

🔄 Comparação entre Treinamentos com 30 e 60 Épocas – YOLOv5


Realizamos dois treinamentos distintos com o modelo YOLOv5, utilizando o mesmo dataset, mas variando a quantidade de épocas: 30 e 60. A seguir, apresentamos uma análise comparativa das principais métricas de desempenho.

📊 Métricas de Avaliação

Métrica	30 Épocas	60 Épocas	Diferença
Precisão (P)	0.87	0.93	+0.06
Revocação (R)	1.00	1.00	=


Métrica	30 Épocas	60 Épocas	Diferença
mAP@0.5	0.982	0.995	+0.013
mAP@0.5:0.95	0.544	0.612	+0.068
Perda total	0.0412	0.0362	-0.005







Interpretação

- O modelo treinado com **60 épocas** apresentou **melhor desempenho em todas as métricas**, especialmente em $\text{mAP}@0.5:0.95$, que é mais exigente.



- A ****perda total foi menor****, indicando que o modelo aprendeu melhor a representar os objetos.

- Ambos os modelos atingiram ****revocação máxima (1.00)****, mas o de 60 épocas teve ****maior precisão****, o que significa menos falsos positivos.



- A evolução entre os dois treinamentos mostra que o modelo continua aprendendo após 30 épocas, sem sinais de overfitting.

✔ Conclusão

Treinamentos mais longos resultam em modelos mais precisos e robustos. Para aplicações reais em visão computacional, recomenda-se utilizar pelo menos **60 épocas** para maximizar o desempenho.

Conclusões

- Modelo com 60 épocas teve melhor desempenho
 - Sistema viável para aplicações reais
 - O modelo com 60 épocas apresentou melhor desempenho geral.
 - O sistema é viável para aplicações reais da FarmTech Solutions, como segurança patrimonial e controle de acessos.
 - A limitação principal foi o tamanho reduzido do dataset, que pode ser expandido em versões futuras.
-

Autores

Grupo 7 — FIAP

- Fátima Vilela Candal
- Gabriel Viel dos Santos Delfino
- Guilherme Campos Hermanowski
- Jonathan Willian Luft
- Matheus Alboredo Soares