Implementando algoritmos de Machine Learning com Scikit-learn

1. Carregamento e Visualização Inicial

Carregar os dados e explorar sua estrutura:

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt


# Definir nomes das colunas
columns = ['Área', 'Perímetro', 'Compacidade', 'Comprimento_Núcleo', 'Largura_Núcleo',
           'Coeficiente_Assimetria', 'Comprimento_Sulco', 'Variedade']

# Ler o arquivo tratando múltiplos espaços como delimitadores
df = pd.read_csv("seeds_dataset.txt", sep="\s+", names=columns)

# Exibir as primeiras linhas
print(df.head())

# Estatísticas descritivas
print(df.describe())

# Verificar valores ausentes
print(df.isnull().sum())

# Visualizar distribuições dos atributos
df.hist(figsize=(12, 8))
plt.show()

# Correlação entre Variáveis
# Calcular correlações
corr_matrix = df.corr()

# Exibir heatmap
plt.figure(figsize=(10, 8))
sns.heatmap(corr_matrix, annot=True, cmap="coolwarm", fmt=".2f")
plt.show()
```

```
    Área  Perímetro  Compacidade  Comprimento_Núcleo  Largura_Núcleo  \
0  15.26      14.84       0.8710               5.763           3.312
1  14.88      14.57       0.8811               5.554           3.333
2  14.29      14.09       0.9050               5.291           3.337
3  13.84      13.94       0.8955               5.324           3.379
4  16.14      14.99       0.9034               5.658           3.562

   Coeficiente_Assimetria  Comprimento_Sulco  Variedade
0                   2.221              5.220          1
1                   1.018              4.956          1
2                   2.699              4.825          1
3                   2.259              4.805          1
4                   1.355              5.175          1
             Área   Perímetro  Compacidade  Comprimento_Núcleo  \
count  210.000000  210.000000   210.000000          210.000000
mean    14.847524   14.559286     0.870999            5.628533
std      2.909699    1.305959     0.023629            0.443063
min     10.590000   12.410000     0.808100            4.899000
25%     12.270000   13.450000     0.856900            5.262250
50%     14.355000   14.320000     0.873450            5.523500
75%     17.305000   15.715000     0.887775            5.979750
max     21.180000   17.250000     0.918300            6.675000

       Largura_Núcleo  Coeficiente_Assimetria  Comprimento_Sulco   Variedade
count      210.000000              210.000000         210.000000  210.000000
mean         3.258605                3.700201           5.408071    2.000000
std          0.377714                1.503557           0.491480    0.818448
min          2.630000                0.765100           4.519000    1.000000
25%          2.944000                2.561500           5.045000    1.000000
50%          3.237000                3.599000           5.223000    2.000000
75%          3.561750                4.768750           5.877000    3.000000
max          4.033000                8.456000           6.550000    3.000000
Área                    0
Perímetro               0
Compacidade             0
Comprimento_Núcleo      0
Largura_Núcleo          0
Coeficiente_Assimetria  0
Comprimento_Sulco       0
Variedade               0
dtype: int64
```

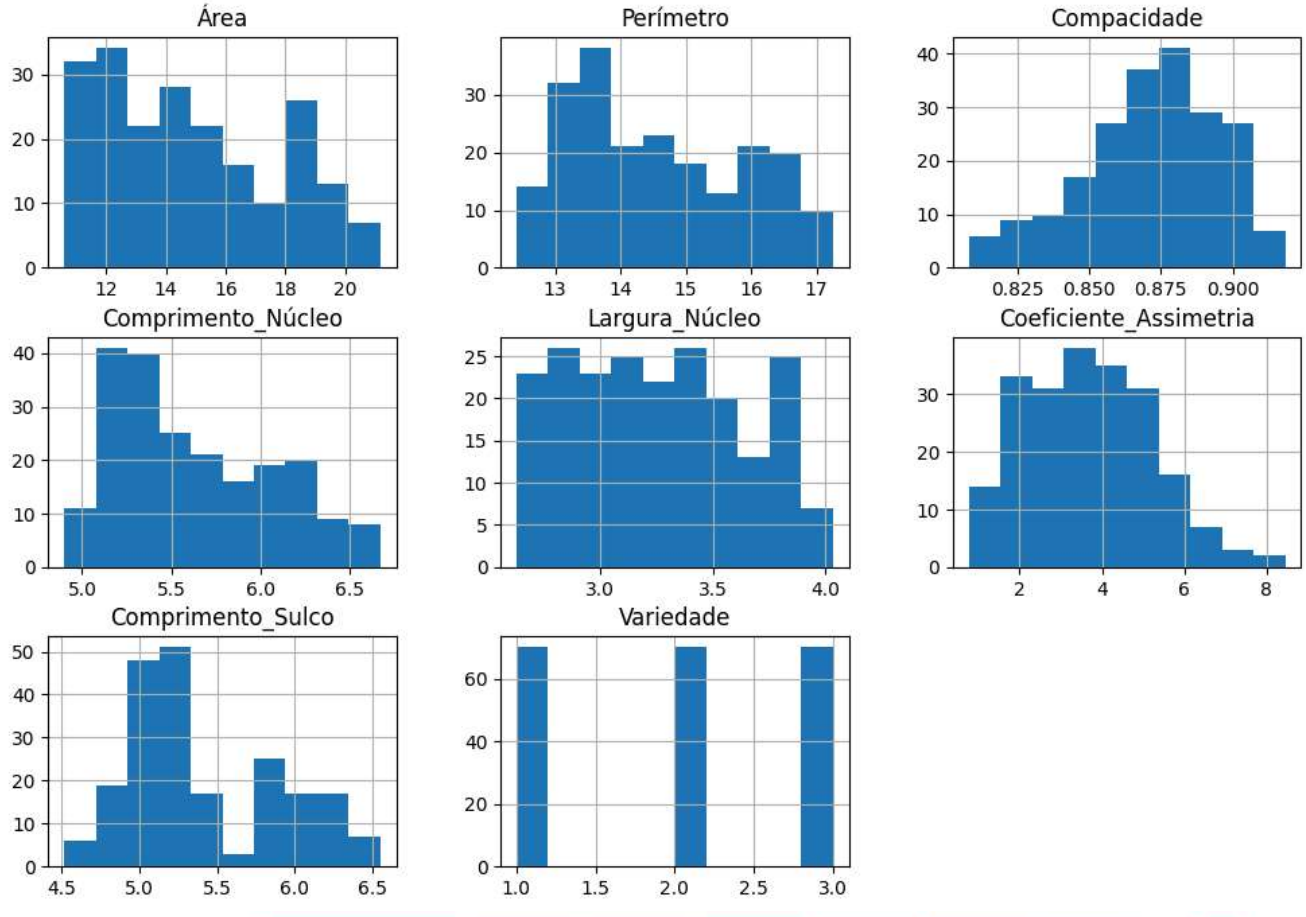

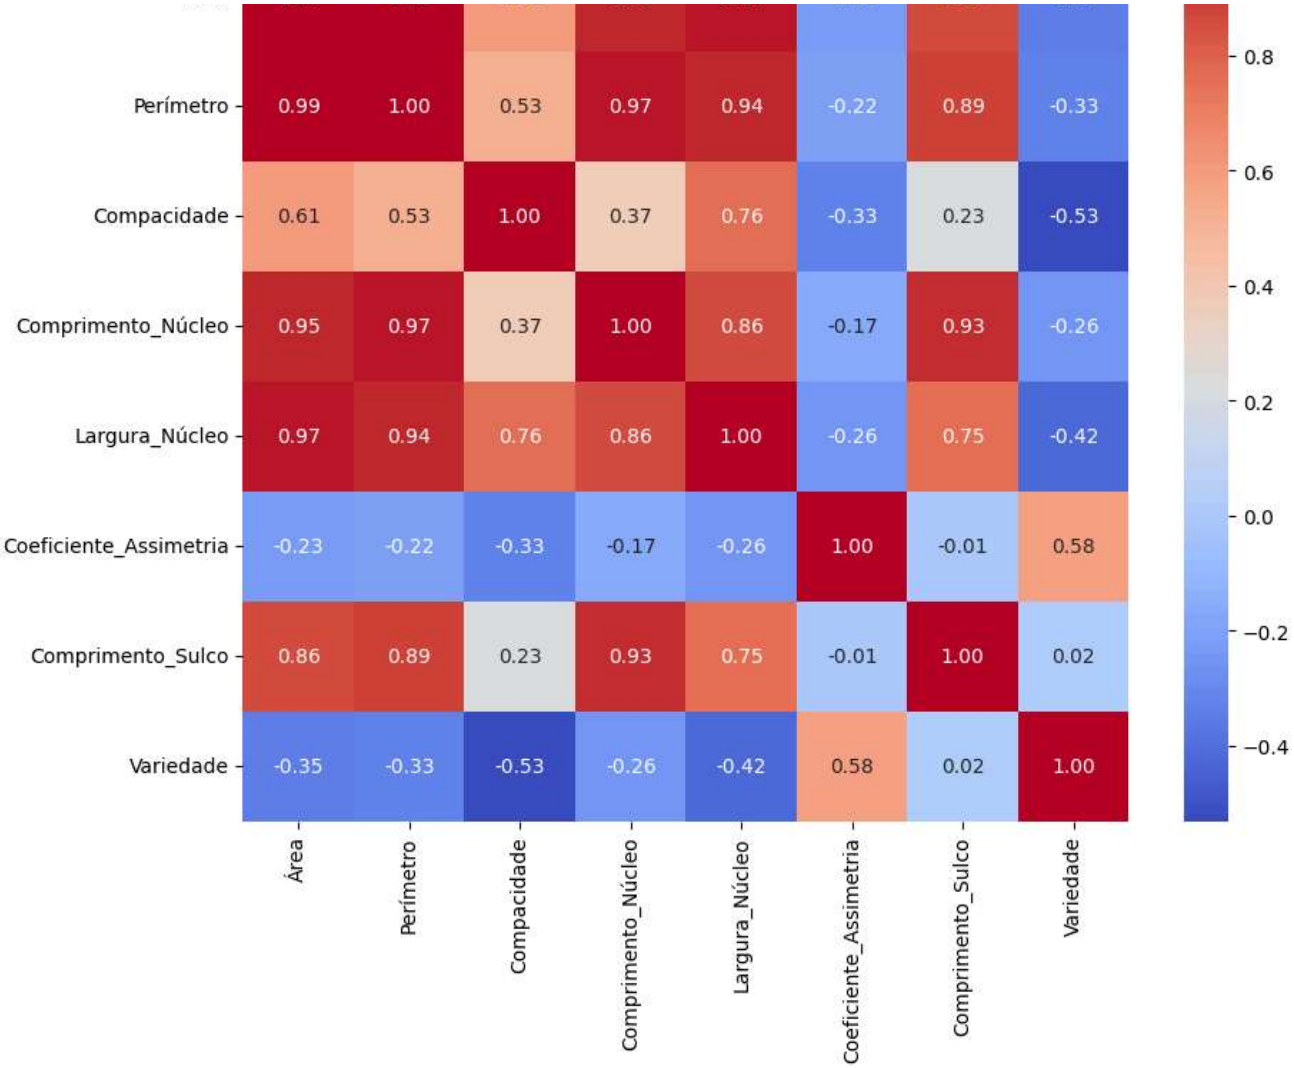
Perímetro
Compacidade
Comprimento_Núcleo
Largura_Núcleo
Coeficiente_Assimetria
Comprimento_Sulco
Variedade
0.99 1.00 0.53 0.97 0.94 -0.22 0.89 -0.33
0.61 0.53 1.00 0.37 0.76 -0.33 0.23 -0.53
0.95 0.97 0.37 1.00 0.86 -0.17 0.93 -0.26
0.97 0.94 0.76 0.86 1.00 -0.26 0.75 -0.42
-0.23 -0.22 -0.33 -0.17 -0.26 1.00 -0.01 0.58
0.86 0.89 0.23 0.93 0.75 -0.01 1.00 0.02
-0.35 -0.33 -0.53 -0.26 -0.42 0.58 0.02 1.00
Área
Perímetro
Compacidade
Comprimento_Núcleo
Largura_Núcleo
Coeficiente_Assimetria
Comprimento_Sulco
Variedade
0.8
0.6
0.4
0.2
0.0
−0.2
−0.4

2. Normalização e Padronização dos Dados

Utilizar MinMaxScaler ou StandardScaler para que as escalas dos atributos não influenciem o modelo.

Aplicar StandardScaler para padronizar os dados, pois os dados possuem magnitudes muito diferentes e deve padronizá-los antes da modelagem.

Aplicar Teste de Shapiro-Wilk para avaliar se uma variável segue uma distribuição normal.

```
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import MinMaxScaler, StandardScaler
from scipy.stats import shapiro

# Definir X (variáveis preditoras) e y (variável alvo)
X = df.iloc[:, :-1]  # Todas as colunas, exceto 'Variedade'
y = df.iloc[:, -1]   # Apenas a coluna 'Variedade'

# Min-Max Scaling
scaler_minmax = MinMaxScaler()
df_minmax = df.copy()
df_minmax.iloc[:, :-1] = scaler_minmax.fit_transform(df.iloc[:, :-1])

# StandardScaler (Z-score)
scaler_standard = StandardScaler()
df_standard = df.copy()
df_standard.iloc[:, :-1] = scaler_standard.fit_transform(df.iloc[:, :-1])


# Executar o teste de normalidade Shapiro-Wilk
for coluna in df.columns[:-1]:  # Ignorando a coluna 'Variedade'
    stat, p = shapiro(df[coluna])
    print(f"{coluna}: Estatística={stat:.3f}, p-valor={p:.3f}")
```

```
Área: Estatística=0.933, p-valor=0.000
Perímetro: Estatística=0.936, p-valor=0.000
Compacidade: Estatística=0.973, p-valor=0.000
Comprimento_Núcleo: Estatística=0.944, p-valor=0.000
Largura_Núcleo: Estatística=0.961, p-valor=0.000
Coeficiente_Assimetria: Estatística=0.984, p-valor=0.015
Comprimento_Sulco: Estatística=0.925, p-valor=0.000
```

3. Separação em Conjuntos de Treinamento e Teste

Dividir os dados para treinar e testar os modelos:

```
from sklearn.model_selection import train_test_split

# Definir X (variáveis preditoras) e y (variável alvo)
X = df.iloc[:, :-1]
y = df['Variedade']

# Divisão dos dados
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42, stratify=y)
```

4. Implementação e Comparação dos Algoritmos de Classificação

Treinar diferentes modelos de classificação e avaliar seu desempenho:

```
from sklearn.neighbors import KNeighborsClassifier
from sklearn.svm import SVC
from sklearn.ensemble import RandomForestClassifier
from sklearn.naive_bayes import GaussianNB
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

# Modelos de classificação
models = {
    "Random Forest": RandomForestClassifier(n_estimators=100, random_state=42),
    "KNN": KNeighborsClassifier(n_neighbors=5),
    "SVM": SVC(kernel='linear'),
    "Logistic Regression": LogisticRegression(max_iter=500),
    "Naive Bayes": GaussianNB(),
}

# Treinar e avaliar cada modelo
results = {}
for name, model in models.items():
    model.fit(X_train, y_train)
    y_pred = model.predict(X_test)
    acc = accuracy_score(y_test, y_pred)
    results[name] = acc
    print(f"\nModelo: {name}")
    print(classification_report(y_test, y_pred))
    print("Matriz de Confusão:")
    print(confusion_matrix(y_test, y_pred))

# Comparação de acurácia
print("\nComparação de Acurácia:")
for model, acc in results.items():
    print(f"{model}: {acc:.4f}")
```

```
[[16  3  2]
 [ 2 19  0]
 [ 1  0 20]]

Modelo: SVM
```

```
 [ 1  0 20]]

Modelo: Naive Bayes
              precision    recall  f1-score   support

           1       0.73      0.76      0.74        21
           2       0.94      0.76      0.84        21
           3       0.83      0.95      0.89        21

    accuracy                           0.83        63
   macro avg       0.83      0.83      0.83        63
weighted avg       0.83      0.83      0.83        63

Matriz de Confusão:
[[16  1  4]
 [ 5 16  0]
 [ 1  0 20]]

Comparação de Acurácia:
Random Forest: 0.9206
KNN: 0.8730
SVM: 0.8571
Logistic Regression: 0.8571
Naive Baves: 0.8254
```

5. Otimização dos Modelos

Utilizar Grid Search para encontrar melhores hiperparâmetros:

```
from sklearn.model_selection import GridSearchCV
from sklearn.preprocessing import StandardScaler

# Otimização do SVM
param_grid = {'C': [0.1, 1, 10], 'kernel': ['linear', 'rbf']}
grid = GridSearchCV(SVC(), param_grid, cv=5)
grid.fit(X_train, y_train)

# Melhor combinação de parâmetros SVM
print("Melhores parâmetros para SVM:", grid.best_params_)

# Otimização do K-Nearest Neighbors (KNN)
# Testar diferentes valores para n_neighbors e o tipo de métrica utilizada:
param_grid_knn = {'n_neighbors': [3, 5, 7, 9], 'weights': ['uniform', 'distance']}
grid_knn = GridSearchCV(KNeighborsClassifier(), param_grid_knn, cv=5)
grid_knn.fit(X_train, y_train)

# Melhor combinação de parâmetros KNN
print("Melhores parâmetros para KNN:", grid_knn.best_params_)


# Otimização do Random Forest
# Explorar o número de árvores na floresta (n_estimators),
# profundidade (max_depth) e critérios de divisão (criterion):
param_grid_rf = {'n_estimators': [50, 100, 150], 'max_depth': [None, 10, 20], 'criterion': ['gini', 'entropy']}
grid_rf = GridSearchCV(RandomForestClassifier(random_state=42), param_grid_rf, cv=5)
grid_rf.fit(X_train, y_train)

# Melhor combinação de parâmetros Randon Forest
print("Melhores parâmetros para Random Forest:", grid_rf.best_params_)


# Otimização do Naive Bayes
# O algoritmo GaussianNB não tem muitos hiperparâmetros para ajustar, mas
# podemos otimizar var_smoothing para melhor regularização:
param_grid_nb = {'var_smoothing': [1e-9, 1e-8, 1e-7, 1e-6]}
grid_nb = GridSearchCV(GaussianNB(), param_grid_nb, cv=5)
```